

PipInstall: определение проплаченных ОТЗЫВОВ

Михаил Кольцов
Борис Симиютин
Леся Тищенко
Михаил Чернявский

7 ноября 2016 г.

План рассказа

- 1 Описание задачи
- 2 Ход работ
 - Предметная область
 - Получение обучающей выборки
 - Используемые признаки
 - Используемые методы и библиотеки
- 3 Результаты
 - Тестирование
 - Возможности продукта
 - Видеодемонстрация

Описание задачи

- делаем классификатор, он обучается на размеченных данных
- определяет хорошие отзывы
- и плохие (проплаченные) отзывы

Решили смотреть только на положительные отзывы.

Хороший отзыв

Достоинства: оповещение по смс, нет очереди, хорошие продавцы, удобный режим работы

Недостатки: много нет в наличии

Комментарий: советую, спасибо

Плохой отзыв

Живу в отдаленном районе, в шаговой доступности есть только продуктовые магазины. Купить телефон удобнее всего с помощью Яндекс.маркета. Я и нашел, где можно подешевле купить нормальный аппарат. Предложение от Opt-Device мне понравилось. Ну я у них и заказал. Позвонил в магазин, уточнил, смогут ли завтра привезти. Менеджер подтвердил, что всё будет так, как я прочитал на сайте. На следующий день приехал курьер и привез мой телефон.

Предметная область

Выбирали из четырёх тем:

- 1 магазины;
- 2 стоматологии;
- 3 отели;
- 4 видео на YouTube.

Каждый взял по одной теме и искал отзывы. После 1.5 часов посоветовались и выбрали **магазины**.

Обучающая выборка

Выделили «маркеры» для проплаченных отзывов:

- 1 мало конкретики;
- 2 длинная предыстория;
- 3 смайлики и восклицательные знаки;
- 4 чем длиннее отзыв, тем более подозрительный;
- 5 мало ошибок или очень глупые ошибки.

Это не идеальная формула – в зависимости от настроения и человека восприятие отзыва может меняться.

Обучающая выборка

Кроме того, задавали вопросы профессиональным составителям отзывов:

- 1 длинный отзыв – скорее всего липовый;
- 2 утрированная эмоциональность от женского лица, безэмоциональность от мужского;
- 3 все магазины покупают отзывы.

Обучающая выборка

Магазин *подозрительный*, если у него мало отзывов и более 90% из них положительные.

- МВидео
- МТС
- Мегафон
- Эльдorado
- Landcom
- Opt-Device
- Telebar.ru
- SLK-Service.ru
- BONCH.PRO
- ProAnima.RU
- Cifrovoi.com
- Apple-Zone

Обучающая выборка

- собираем по 100 отзывов для каждого магазина;
- всего 1200 отзывов;
- используем API Я.Маркета, всё храним в JSON;
- размечаем в самописном интерфейсе.

Обучающая выборка

- размечаем в самописном интерфейсе.
- ВОТ В ТАКОМ:

data2.json

Счетчик:

190/300

Оценка:

4

Автор:

Петрова Нина

Достоинства:

Ассортимент - широкий, продуманный. Цены, конечно.

Недостатки:

Мало аксессуаров, количественно.

Комментарии:

Мне не нравится красный цвет в его дизайне. Красный - это не цвет торговли барахлом, а цвет крови, страсти, мучения, искушения... В общем, цинизмом от такой неуместности веет.

Обучающая выборка

- каждый голосует за каждый отзыв, считает ли он его оплаченным или нет
- результаты разметки:
 - двое и более проголосовало за один вариант: 300 хороших, 714 оплаченных
 - решение единогласное: 255 хороших, 42 оплаченных
- единогласных маловато

Используемые признаки

- количество местоимений в первом/втором лице;
- количество КАПСОВЫХ слов;
- длина отзыва;
- количество противопоставлений;
- гистограмма частей речи;

Используемые признаки

- гистограмма букв/слов в отзыве;
- количество смайликов, восклицательных знаков;
- средняя длина слова;
- количество синонимов внутри отзыва;
- мета-информация: об авторе, о магазине, ...
- количество грамматических ошибок.

Ссылки на реализацию: <https://github.com/ItsLastDay/PipInstall/wiki/ML-features>

Анализ полезности признаков

Здесь слайд(ы) про то, какие признаки как повлияли на качество классификатора; как мы оценивали полезность (в том числе визуально) и т.п.

Используемые методы и библиотеки

- библиотеки: enchant, nltk, pymystem3, sklearn, matplotlib;
- нашли словарь синонимов;
- изучали литературу по review spam detection, особенно «Crawford M. et al. Survey of review spam detection using machine learning techniques //Journal of Big Data. – 2015.»;
- реализовали метод по расширению размеченных данных.

Используемые методы и библиотеки

Здесь слайд(ы) про то, как мы использовали какие библиотеки, какие классификаторы пробовали, как выбирали.

Результаты. Тестирование

- взяли отзывы, по которым есть консенсус среди размечавших;
- отложили часть из них для тестирования;
- расширили данные с помощью неразмеченных отзывов;
- обучились, протестировались.

65%

Результаты. Сравнение

Paper	Dataset	Features used	Learner	Performance metric	Score	Method complexity
[20]	5.8 million reviews written by 2.14 reviewers crawled from amazon website	Review and reviewer features	LR	AUC	78 %	Low
[21]	5.8 million reviews written by 2.14 reviewers crawled from amazon website	Features of the review, reviewer and product characteristics	LR	AUC	78 %	Medium
[21]	5.8 million reviews written by 2.14 reviewers crawled from amazon website	Text features	LR	AUC	63 %	Low
[9]	6000 reviews from Epinions	Review and reviewer features	NB with Co-training	F-Score	0.631	High
[3]	Hotels through Amazon Mechanical Turk (AMT) by Ott et al.	Bigrams	SVM	Accuracy	89.6 %	Low
[3]	Hotels through Amazon Mechanical Turk (AMT) by Ott et al.	LIWC + Bigrams	SVM	Accuracy	89.8 %	Medium
[25]	Hotels through Amazon Mechanical Turk (AMT) by Ott et al. + gathered 400	LIWC + POS + Unigram	SAGE	Accuracy	65 %	High

Возможности продукта

- направляем классификатор на отзывы с Я.Маркета => он даёт ответы;
- работает быстро;
- результат работы спорный.

Видеодемонстрация

TODO

Спасибо за внимание!