# PipInstall: определение проплаченных отзывов

Михаил Кольцов
Борис Симиютин
Леся Тищенко
Михаил Чернявский

5 ноября 2016 г.

#### План рассказа

- Описание задачи
- 2 Ход работ
  - Предметная область
  - Получение обучающей выборки
  - Используемые признаки
  - Используемые методы и библиотеки
- Результаты
  - Тестирование
  - Возможности продукта
  - Видеодемонстрация

#### Описание задачи

- делаем классификатор, он обучается на размеченных данных
- определяет хорошие отзывы
- и плохие (проплаченные) отзывы

Решили смотреть только на положитьельные отзывы.

#### Хороший отзыв

Достоинства:оповещение по смс, нет очереди, хорошие продавцы, удобный режим работы Недостатки:многого нет в наличии Комментарий: советую, спасибо

#### Плохой отзыв

Живу в отдаленном районе, в шаговой доступности есть только продуктовые магазины. Купить телефон удобнее всего с помощью Яндекс.маркета. Я и нашел, где можно подешевле купить нормальный аппарат. Предложение от Opt-Device мне понравилось. Ну я у них и заказал. Позвонил в магазин, уточнил, смогут ли завтра привезти. Менеджер подтвердил, что всё будет так, как я прочитал на сайте. На следующий день приехал курьер и привез мой телефон.

## Предметная область

Выбирали из четырёх тем:

- 💶 магазины;
- стоматологии;
- отели;
- видео на YouTube.

Каждый взял по одной теме и искал отзывы. После 1.5 часов посовещались и выбрали **магазины**.

Выделили «маркеры» для проплаченных отзывов:

- 💶 мало конкретики;
- длинная предыстория;
- смайлики и восклицательные знаки;
- чем длиннее отзыв, тем более подозрительный;
- 🧿 мало ошибок или очень глупые ошибки.

Это не идеальная формула — в зависимости от настроения и человека восприятие отзыва может меняться.

Кроме того, задавали вопросы профессиональным составителям отзывов:

- длинный отзыв скорее всего липовый;
- утрированная эмоциональность от женского лица, безэмоциональность от мужского;
- 🧿 все магазины покупают отзывы.

Магазин *подозрительный*, если у него мало отзывов и более 90% из них положительные.

- МВидео
- MTC
- Мегафон
- Эльдорадо

- Landcom
- Opt-Device
- Telebar.ru
- SLK-Service.ru
- BONCH.PRO
- ProAnima RU

- Cifrovoi.com
- Apple-Zone

- собираем по 100 отзывов для каждого магазина;
- всего 1200 отзывов;
- используем API Я.Маркета, всё храним в JSON;
- размечаем в самописном интерфейсе.

Здесь слайд(ы) про интерфейс и статистику: сколько отзывов положительных набрали, по скольким отзывам есть консенсус среди размечавших людей (>= 2, >= 3 людей). Можно с примерами.

#### Используемые признаки

- количество местоимений в первом/втором лице;
- количество КАПСОВЫХ слов;
- длина отзыва;
- количество противопоставлений;
- гистограмма частей речи;

#### Используемые признаки

- гистограмма букв/слов в отзыве;
- количество смайликов, восклицательных знаков;
- средняя длина слова;
- количество синонимов внутри отзыва;
- мета-информация: об авторе, о магазине, ...
- количество грамматических ошибок.

Ссылки на реализацию: https://github.com/ ItsLastDay/PipInstall/wiki/ML-features

#### Анализ полезности признаков

Здесь слайд(ы) про то, какие признаки как повлияли на качество классификатора; как мы оценивали полезность (в том числе визуально) и т.п.

#### Используемые методы и библиотеки

- библиотеки: enchant, nltk, pymystem3, sklearn, matplotlib;
- нашли словарь синонимов;
- поизучали литературу по review spam detection, особенно «Crawford M. et al. Survey of review spam detection using machine learning techniques //Journal of Big Data. – 2015.»;
- реализовали метод по расширению размеченных данных.

### Используемые методы и библиотеки

Здесь слайд(ы) про то, как мы использовали какие библиотеки, какие классификаторы пробовали, как выбирали.

#### Результаты. Тестирование

- взяли отзывы, по которым есть консенсус среди размечавших;
- отложили часть из них для тестирования;
- расширили данные с помощью неразмеченных отзывов;
- обучились, протестировались.

## Результаты. Тестирование



## Результаты. Сравнение

by Ott et al.

Hotels through Amazon

Mechanical Turk (AMT) by

Ott et al. + gathered 400

[25]

Paper	Dataset	Features used	Learner	Performance metric	Score	Method complexit
[20]	5.8 million reviews written by 2.14 reviewers crawled from amazon website	Review and reviewer features	LR	AUC	78 %	Low
[21]	5.8 million reviews written by 2.14 reviewers crawled from amazon website	Features of the review, reviewer and product characteristics	LR	AUC	78 %	Medium
[21]	5.8 million reviews written by 2.14 reviewers crawled from amazon website	Text features	LR	AUC	63 %	Low
[9]	6000 reviews from Epinions	Review and reviewer features	NB with Co-training	F-Score	0.631	High
[3]	Hotels through Amazon Mechanical Turk (AMT) by Ott et al.	Bigrams	SVM	Accuracy	89.6 %	Low
[3]	Hotels through Amazon Mechanical Turk (AMT)	LIWC + Bigrams	SVM	Accuracy	89.8 %	Medium

LIWC + POS + Unigram SAGE

11 / 14

High

65 %

Accuracy

#### Возможности продукта

- натравливаем классификатор на отзывы с Я.Маркета => он даёт ответы;
- работает быстро;
- результат работы спорный.

## Видеодемонстрация

TODO

Спасибо за внимание!